

이진원

AI 플랫폼 소프트웨어 & SRE 엔지니어

서울, 대한민국 | +82 10-2422-1429 | dlwlsdnjsehs1993@gmail.com |
github.com/JINwonLEE | linkedin.com/in/jwl1993
"일단 만들고 그 다음에 생각하자."

지원 포지션 적합도

- AI 플랫폼 소프트웨어
- MLOps / 모델 서빙
- Kubernetes 인프라
- 시스템 소프트웨어

요약

삼성전자에서 생성형 AI 서비스와 사내 LLM 플랫폼의 SRE/플랫폼 엔지니어링을 담당하고 있습니다. 약 8년 동안 Kubernetes 기반 서비스 운영, 클라우드 인프라 자동화, CI/CD, 관측 가능성, AI 평가/서빙 워크플로우를 다뤄왔습니다.

제가 잘하는 일은 AI 애플리케이션을 "동작하는 코드"에서 실제 사용자가 안정적으로 쓸 수 있는 운영 구조로 옮기는 것입니다. 배포, 인증, 모니터링, 장애 대응, 리소스 제약을 함께 고려해 애플리케이션이 원활하게 동작할 수 있는 플랫폼을 만듭니다.

AI 플랫폼 소프트웨어

MLOps & 모델 서빙

시스템 소프트웨어 & 성능

클라우드/Kubernetes 인프라

핵심 역량

AI/MLOps	LLM 평가 파이프라인, MLflow 메트릭 추적, AI 서빙 운영, Document LLM 플랫폼, Langfuse 관측 가능성
플랫폼	Kubernetes, Azure, AWS, OpenShift, Docker, Helm/Helmfile, ArgoCD, GitOps, Terraform, Ansible
시스템	Linux 런타임 동작, Python 자동화, 고성능 패킷 미러링, 분산 시스템, 리소스 인식 최적화
신뢰성	Grafana, Prometheus, OpenTelemetry, Loki, Keycloak/OAuth, DevSecOps 검증, 장애 대응형 운영

경력

삼성전자 (AX Development Group)

서울, 대한민국

SRE / AI 플랫폼 엔지니어

2026.01 - 현재

- KT 및 Microsoft와 협업하여 Microsoft Azure 기반 글로벌 B2C 생성형 AI 서비스를 설계 및 관리하고, 네트워크 설계와 다중 리전 준비를 담당했습니다.
- 프로덕션 AI 워크로드를 위한 AI 서빙 성능과 서비스 효율을 최적화하고, 보안 정책과 인프라 거버넌스를 설계했습니다.
- ArgoCD와 Python을 활용한 GitOps 기반 CI/CD 파이프라인을 구축하고 정적 코드 분석, 컨테이너 이미지 스캐닝 등 DevSecOps 검증을 연동했습니다.
- 브라우저 통합 AI 및 Document LLM 플랫폼의 Kubernetes 기반 MLOps/서빙 운영을 담당하고 Keycloak, OAuth, Langfuse 기반 인증/관측성 체계를 구축했습니다.

삼성리서치 (Samsung Research)

서울, 대한민국

SRE / AI 플랫폼 엔지니어

2024.07 - 2025.12

- Microsoft Azure 기반 글로벌 챗봇 서비스를 설계 및 운영하고 외부 파트너와 협력하여 다중 리전 프로덕션 배포를 준비했습니다.
- 약 30,000명의 임직원이 사용하는 전사 AI 챗봇 플랫폼의 Kubernetes 기반 인프라, 플랫폼, 애플리케이션 운영을 담당했습니다.
- Helm/Helmfile을 활용하여 개발, 스테이징, 프로덕션 Kubernetes 클러스터를 프로비저닝하고 운영했습니다.
- Docker, Kubernetes, GitHub Actions, ArgoCD를 활용해 컨테이너화된 애플리케이션의 CI/CD 파이프라인을 구축했습니다.
- Grafana, Prometheus, OpenTelemetry 기반 중앙 모니터링을 배포하고, 기계 번역 태스크용 LLM 평가 자동화 파이프라인을 구축했습니다.

경력 (계속)

삼성전자 (Network Dept.)

서울, 대한민국

SRE & 소프트웨어 엔지니어

2021.01 - 2024.06

- Docker, Helm, Kubernetes Operator 및 AWS(EKS, ECS, Route 53, RDS, IAM 등)를 활용해 컨테이너화된 애플리케이션을 배포했습니다.
- OpenShift, Kubernetes, EKS 환경을 구축/관리하며 성능, 안정성, 고가용성, 오토스케일링을 고려한 운영을 수행했습니다.
- 클라우드 개발자를 위한 Kubernetes 클러스터 원클릭 프로비저닝 시스템을 개발했습니다.
- 제한된 시스템 리소스에서 초당 최대 130,000개의 패킷을 실시간으로 미러링해 타겟 서버로 전달하는 애플리케이션을 개발했습니다.

티맥스OS & 티맥스클라우드

경기, 대한민국

소프트웨어 & 플랫폼 엔지니어

2019.01 - 2020.12

- Kubernetes 환경에서 CI/CD 및 레지스트리 오퍼레이터를 개발하고 프라이빗 컨테이너 이미지 레지스트리를 배포했습니다.
- TmaxOS 기반 Siri형 AI 어시스턴트를 개발하며 시스템 수준 통합, AI 모델 추론, 데이터 전처리, 비동기 아키텍처를 담당했습니다.

학력

UNIST (울산과학기술원)

2017.03 - 2019.02

M.S. 컴퓨터 공학과

- 석사 졸업 논문: Convergence Aware CNN Training
- 지도교수: 서지원 (한양대학교), 노삼혁 (UNIST)

UNIST (울산과학기술원)

2012.03 - 2017.02

B.S. 컴퓨터 공학과; 부전공 수학

- 학부 연구: TensorFlow 기반 AI 모델 학습을 위한 분산 시스템

논문/발표

- Alleviating the Network Bottleneck for CNN Distributed Training through Automatic Resource-Aware Layer Placement, USENIX NSDI 2019 poster.
- Accelerated Training for CNN Distributed Deep Learning through Automatic Resource-Aware Layer Placement, arXiv 2019.
- Improving Performance of Distributed TensorFlow using CNN Characteristics Exploiting Model Parallelism, ACM EuroSys 2018 poster.