이진원

AI 플랫폼 & 신뢰성 엔지니어

서울, 대한민국 | +82 10-2422-1429 | dlwlsdnjsehs1993@gmail.com
github.com/JINwonLEE | linkedin.com/in/jwl1993

프로필

약 8년 동안 거버넌스형 Agent App, 클라우드 플랫폼 및 사용자 대상 서비스를 프로덕션까지 전달해 온 AI 플랫폼·신뢰성 엔지니어입니다.

Agent 런타임 연동, 배포 자동화, 접근 제어, 관측, 장애 대응 및 프로덕션 안정화를 설계부터 운영까지 직접 이어갑니다.

핵심 근거

AWS EKS 기반 거버넌스·셀프서비스 AX App 배포 플랫폼	30,000명 임직원 대상 전사 AI 서비스 프로덕션 신뢰성	글로벌 B2C 생성형 AI 서비스 UK 출시·장애 대응·초기 안정화

핵심 역량

Agent 플랫폼	AWS EKS, Agent 런타임 연동, 셀프서비스 배포, 도메인 자동 발급, 기존 LLM Gateway API 연동
신뢰성	Grafana, Prometheus, OpenTelemetry, 장애 대응, 출시 안정화, 고가용성, 오토스케일링
소프트웨어 & 배포	Python, Bash, Linux, Kubernetes Operator, ArgoCD, GitHub Actions, GitOps, Helm/Helmfile
보안 & 거버넌스	인증, 인가, 플랫폼 보안 통제, 정책 적용, 엔터프라이즈 거버넌스

경력

삼성전자 AX Development Group

서울, 대한민국
SRE / AI 플랫폼 엔지니어
2026.01 - 현재

- AWS EKS 기반 사내 AX Agent Platform을 설계·구축하고, 에이전트 런타임과 배포 경로를 사내 플랫폼 표준에 맞게 조정했습니다.
- 도메인 자동 발급과 인가된 사용자 전용 접근을 포함한 AX App 셀프서비스 배포 흐름을 구현하고 인증·인가·보안·거버넌스 통제를 담당했습니다.
- AX App이 기존 사내 LLM Gateway API를 호출할 수 있도록 플랫폼 측 클라이언트 호환성과 런타임 연동을 제공했습니다.
- 2026.01~06 Microsoft와 협업한 B2C 생성형 AI 서비스의 UK 출시 준비, 초기 운영, 장애 대응 및 안정화를 수행했습니다.

Samsung Research

서울, 대한민국
SRE / AI 플랫폼 엔지니어
2024.07 - 2025.12

- 30,000명의 임직원이 사용하는 전사 AI 챗봇의 프로덕션 전달과 애플리케이션 신뢰성을 리딩했습니다.
- 개발·스테이징·프로덕션 릴리스를 담당하며 애플리케이션 전달을 보안 및 운영 요구사항과 연결했습니다.
- Docker, Kubernetes, GitHub Actions, ArgoCD, Helm, Helmfile 기반 컨테이너 전달 파이프라인을 구축했습니다.
- Grafana, Prometheus, OpenTelemetry 관측 환경을 구축해 서비스 가시성과 운영 진단 체계를 강화했습니다.

삼성전자 네트워크사업부

서울, 대한민국
SRE & 소프트웨어 엔지니어
2021.01 - 2024.06

- Docker, Helm, Kubernetes Operator와 AWS EKS, ECS, Route 53, RDS, IAM을 활용해 컨테이너 애플리케이션을 설계·전달했습니다.
- 신뢰성·고가용성·성능·오토스케일링을 고려한 OpenShift, Kubernetes, EKS 환경을 구축·관리했습니다.
- Bash 기반 원클릭 Kubernetes 클러스터 프로비저닝 시스템을 설계·개발했습니다.
- 제한된 시스템 리소스에서 초당 최대 130,000개 패킷을 미러링·전달하는 Linux 애플리케이션을 개발했습니다.

TmaxOS & TmaxCloud

경기, 대한민국
소프트웨어 & 플랫폼 엔지니어
2019.01 - 2020.12

- TmaxOS 기반 Siri형 AI 어시스턴트의 모델 추론, 데이터 전처리, 시스템 연동 및 비동기 애플리케이션 흐름을 개발했습니다.
- Kubernetes CI/CD 및 레지스트리 Operator를 설계·개발하고 프라이빗 컨테이너 이미지 레지스트리를 배포했습니다.

주요 엔지니어링 작업

사내 AX Agent Platform

AWS EKS에서 런타임 조정, 도메인 자동 발급, 인가된 사용자 전용 접근 및 기존 사내 LLM Gateway API 연동을 제공하는 거버넌스형 AX App 배포 플랫폼을 구축했습니다.

관측 환경 & 릴리스 신뢰성

Grafana, Prometheus, OpenTelemetry를 구축하고 개발·스테이징·프로덕션 Kubernetes 릴리스를 보안 및 운영 요구사항과 연결했습니다.

글로벌 B2C 생성형 AI 서비스

Microsoft와 협업한 Azure 기반 소비자 AI 서비스의 UK 출시 준비, 초기 프로덕션 운영, 장애 대응 및 안정화를 수행했습니다.

LLM 기반 클러스터 모니터링 | 개인 프로젝트

사내 클러스터의 오류를 감지하고 LLM으로 분석해, 문제 요약·분석 내용·해결 방법을 이메일로 전달하는 모니터링 시스템을 만들었습니다.

오퍼나우 (OfferNow) | 개인 프로젝트, 2026.09 - 현재

CV(PDF/DOCX)를 근거 기반 경력 프로필로 바꾸고, robots.txt를 지키며 50여 개 기업의 공식 채용 공고를 수집해 추천마다 공고 요건과 CV 근거를 함께 보여주는 IT 채용 추천 서비스를 만들고 있습니다. Expo(웹·iOS·Android), FastAPI, PostgreSQL 행 수준 보안(RLS), 사용자별 한도와 비용 기록을 갖춘 공급자 중립 LLM 연동, Docker Compose·nginx 배포.

수상 및 활동

SK하이닉스 AI 해커톤 2026 본선 진출

2026.11

온라인 1·2차 예선(AI 기초·활용 역량, AI Native 역량 검증)을 통과해 오프라인 본선에 진출 (개인 참가)

학력 & 연구

UNIST | 컴퓨터공학 석사

2017.03 - 2019.02

석사 논문: Convergence Aware CNN Training | 지도교수: 서지원, 노삼혁

UNIST | 컴퓨터공학 학사, 수학 부전공

2012.03 - 2017.02

학부 연구: TensorFlow 기반 AI 모델 학습을 위한 분산 시스템

논문 & 어학

- USENIX NSDI 2019 poster: Alleviating the Network Bottleneck for CNN Distributed Training through Automatic Resource-Aware Layer Placement.
- arXiv 2019: Accelerated Training for CNN Distributed Deep Learning through Automatic Resource-Aware Layer Placement.
- ACM EuroSys 2018 poster: Improving Performance of Distributed TensorFlow using CNN Characteristics Exploiting Model Parallelism.
- OPIc IH (Intermediate High), 2025.12.