

프로필

약 8년 동안 애플리케이션 소프트웨어, 클라우드 플랫폼, 보안 및 운영을 아우르며 엔터프라이즈·사용자 대상 시스템을 프로덕션까지 전달해 온 AI·플랫폼 엔지니어입니다.

아키텍처와 구현부터 연동, 출시, 관측, 장애 대응 및 초기 안정화까지 직접 이어가는 것이 강점입니다.

핵심 근거

AWS EKS 기반 거버넌스·셀프서비스 AX App
배포 플랫폼

30,000명 임직원 대상 전사 AI 서비스
프로덕션 신뢰성

초당 최대 130,000개 패킷 처리 Linux
애플리케이션

핵심 역량

클라우드 & 플랫폼

AWS EKS, Azure, Kubernetes, OpenShift, Docker, Helm/Helmfile, ArgoCD, GitOps

소프트웨어

Python, Bash, Linux, Kubernetes Operator, API·런타임 연동, 비동기 흐름

신뢰성 & 보안

Grafana, Prometheus, OpenTelemetry, 장애 대응, 인증·인가, 보안 거버넌스

Applied AI

Agent App 전달, MLflow 기반 LLM 평가, 기존 LLM Gateway API 연동, 모델 추론

경력

삼성전자 AX Development Group

서울, 대한민국

SRE / AI 플랫폼 엔지니어

2026.01 - 현재

- AWS EKS 기반 사내 AX Agent Platform을 설계·구축하고, 에이전트 런타임과 배포 경로를 사내 플랫폼 표준에 맞게 조정했습니다.
- 도메인 자동 발급과 인가된 사용자 전용 접근을 포함한 AX App 셀프서비스 배포 흐름을 구현하고 인증·인가·보안·거버넌스 통제를 담당했습니다.
- AX App이 기존 사내 LLM Gateway API를 호출할 수 있도록 플랫폼 측 클라이언트 호환성과 런타임 연동을 제공했습니다.
- 2026.01~06 Microsoft와 협업한 B2C 생성형 AI 서비스의 UK 출시 준비, 초기 운영, 장애 대응 및 안정화를 수행했습니다.

Samsung Research

서울, 대한민국

SRE / AI 플랫폼 엔지니어

2024.07 - 2025.12

- 30,000명의 임직원이 사용하는 전사 AI 챗봇의 프로덕션 전달과 애플리케이션 신뢰성을 리딩했습니다.
- 개발·스테이징·프로덕션 릴리스를 담당하며 애플리케이션 전달을 보안 및 운영 요구사항과 연결했습니다.
- Docker, Kubernetes, GitHub Actions, ArgoCD, Helm, Helmfile 기반 컨테이너 전달 파이프라인을 구축했습니다.
- Grafana, Prometheus, OpenTelemetry 관측 환경과 Python/MLflow 기반 기계 번역 LLM 평가 워크플로우를 구축했습니다.

삼성전자 네트워크사업부

서울, 대한민국

SRE & 소프트웨어 엔지니어

2021.01 - 2024.06

- Docker, Helm, Kubernetes Operator와 AWS EKS, ECS, Route 53, RDS, IAM을 활용해 컨테이너 애플리케이션을 설계·전달했습니다.
- 신뢰성·고가용성·성능·오토스케일링을 고려한 OpenShift, Kubernetes, EKS 환경을 구축·관리했습니다.
- Bash 기반 원클릭 Kubernetes 클러스터 프로비저닝 시스템을 설계·개발했습니다.
- 제한된 시스템 리소스에서 초당 최대 130,000개 패킷을 미러링·전달하는 Linux 애플리케이션을 개발했습니다.

경력 (계속)

TmaxOS & TmaxCloud

경기, 대한민국

소프트웨어 & 플랫폼 엔지니어

2019.01 - 2020.12

- TmaxOS 기반 Siri형 AI 어시스턴트의 모델 추론, 데이터 전처리, 시스템 연동 및 비동기 애플리케이션 흐름을 개발했습니다.
- Kubernetes CI/CD 및 레지스트리 Operator를 설계·개발하고 프라이빗 컨테이너 이미지 레지스트리를 배포했습니다.

주요 엔지니어링 작업

Enterprise AI Assistant | 공개 레퍼런스 구현

jinwonlee.github.io/projects/enterprise-ai-assistant/web/

SQLite FTS5 검색, 생성 전 역할 기반 권한 필터, 근거 인용, 감사 이벤트, 평가 케이스, FastAPI 및 선택적 OpenAI Responses API 연동을 구현했습니다.

LLM 성능 평가 파이프라인

Kubernetes에서 기계 번역 모델을 반복 평가·비교할 수 있도록 Python/MLflow 워크플로우를 구축했습니다.

분산 CNN 학습 연구

분산 TensorFlow 학습의 리소스 인지 레이어 배치 연구에 참여해 발표 자료에서 최대 2.3배 학습 속도 향상을 보고했습니다.

고처리량 패킷 미러링

제한된 리소스에서 초당 최대 130,000개 패킷을 미러링·전달하도록 Linux 데이터 경로 애플리케이션을 개발·튜닝했습니다.

학력 & 연구

UNIST | 컴퓨터공학 석사

2017.03 - 2019.02

석사 논문: Convergence Aware CNN Training | 지도교수: 서지원, 노삼혁

UNIST | 컴퓨터공학 학사, 수학 부전공

2012.03 - 2017.02

학부 연구: TensorFlow 기반 AI 모델 학습을 위한 분산 시스템

논문 & 어학

- USENIX NSDI 2019 poster: Alleviating the Network Bottleneck for CNN Distributed Training through Automatic Resource-Aware Layer Placement.
- arXiv 2019: Accelerated Training for CNN Distributed Deep Learning through Automatic Resource-Aware Layer Placement.
- ACM EuroSys 2018 poster: Improving Performance of Distributed TensorFlow using CNN Characteristics Exploiting Model Parallelism.
- OPic IH (Intermediate High), 2025.12.