이진원

Agent 플랫폼 · Applied AI · 신뢰성

웹사이트

https://jinwonlee.github.io/

이 포트폴리오는 Agent App을 엔터프라이즈 요구사항에서 안정적인 프로덕션까지 전달하는 플랫폼과 신뢰성 엔지니어링 경험을 정리한 문서입니다. 각 프로젝트는 문제 상황, 담당 역할, 설계와 전달 포인트, 결과를 중심으로 구성했습니다.

Agent 플랫폼

Agent 런타임 연동, 셀프서비스 App 배포, 기존 LLM Gateway API 연결

거버넌스형 배포

인증·인가, 보안 통제, 자동 도메인 및 엔터프라이즈 거버넌스

신뢰성

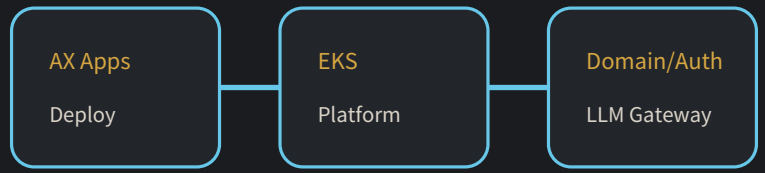
관측 가능성, 장애 대응, 출시 준비 및 프로덕션 안정화

클라우드 런타임

AWS EKS, Azure, OpenShift, Kubernetes, Helm 및 ArgoCD

프로젝트 상세

문제 상황, 역할, 설계/전달 포인트, 결과, 역량 포인트

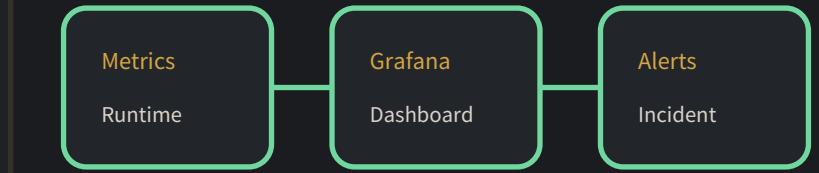


01. 사내 AX Agent Platform

자동 도메인, 접근 제어, 거버넌스, LLM Gateway 연동을 제공하는 AWS EKS 기반 AX App 배포·운영 플랫폼

문제	개발팀이 AX App을 빠르게 배포하면서도 사내 접근 제어, 보안, AI 거버넌스를 일관되게 적용할 수 있어야 했습니다.
역할	아키텍처와 구현부터 배포·운영까지 플랫폼 전달 전 과정을 담당하고 인증·인가·보안 및 사내 거버넌스를 책임졌습니다.
설계/전달	AWS EKS, AX Agent 런타임 조정, 도메인 자동 발급, 접근 제어, 정책 적용, 기존 LLM Gateway 클라이언트 연동
결과	자동 도메인과 인가 사용자 전용 접근을 갖춘 AX App 셀프서비스 배포 경로를 구축했습니다.
역량 포인트	런타임 호환성, 셀프서비스 배포, 접근 제어, 사내 LLM 연동을 하나의 거버넌스 플랫폼으로 구현한 경험입니다.

AWS · EKS · Kubernetes · 인증/인가 · 거버넌스



02. 중앙 집중식 모니터링 & 관측성 스택

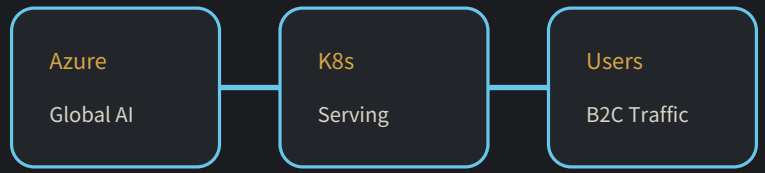
시스템 메트릭, 컨테이너 런타임 메트릭, 대시보드, 알림을 위한 중앙 관측성 스택

문제	프로덕션 서비스의 시스템 동작과 컨테이너 런타임 상태를 공통으로 볼 수 있는 체계가 필요했습니다.
역할	플랫폼 및 서비스 운영에 쓰이는 모니터링 경로와 대시보드를 구축했습니다.
설계/전달	Prometheus 메트릭, Grafana 대시보드, OpenTelemetry 신호, Loki 로그, 알림 규칙
결과	인시던트 탐지와 런타임 분석을 위한 운영 가시성을 높였습니다.
역량 포인트	시스템 메트릭, 로그, 트레이스를 모아 장애 탐지와 런타임 분석에 활용한 경험입니다.

Grafana · Prometheus · OpenTelemetry · Loki

프로젝트 상세

문제 상황, 역할, 설계/전달 포인트, 결과, 역량 포인트

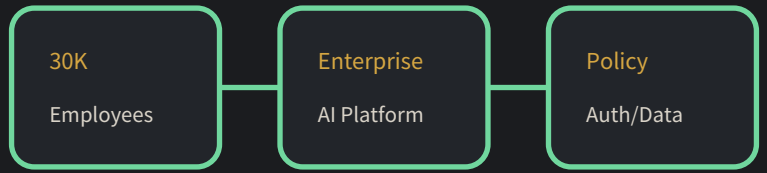


03. 글로벌 B2C 생성형 AI 서비스

Microsoft Azure 기반 B2C 생성형 AI 서비스의 UK 확장, 초기 프로덕션 운영 및 장애 대응

문제	소비자 대상 생성형 AI 서비스를 UK로 확장하고 초기 프로덕션 운영을 안정화해야 했습니다.
역할	UK 출시 준비, 초기 프로덕션 운영, 장애 대응 및 초기 안정화를 위한 플랫폼/SRE 업무를 수행했습니다.
설계/전달	Azure 및 Kubernetes 운영, 출시 준비, 프로덕션 안정화, 장애 대응
결과	UK 출시와 초기 안정화를 지원하고 2026년 6월 해당 업무를 마무리했습니다.
역량 포인트	소비자 대상 생성형 AI 서비스의 UK 출시 준비, 초기 안정화, 장애 대응을 수행한 경험입니다.

Azure · Kubernetes · 생성형 AI · SRE · 장애 대응



04. 전사 AI 챗봇 플랫폼 (약 3만 사용자)

30,000명 임직원이 사용하는 엔터프라이즈 AI 챗봇 플랫폼의 Kubernetes 기반 애플리케이션 전달, 신뢰성, 데이터 보호

문제	수만 명의 임직원이 안정적으로 사용할 수 있는 내부 AI 어시스턴트 플랫폼이 필요했습니다.
역할	개발·스테이징·프로덕션 전반의 플랫폼 및 애플리케이션 신뢰성을 리딩하고 릴리스와 보안·운영 요구사항을 연결했습니다.
설계/전달	Kubernetes 운영, Helm/Helmfile IaC, AI 서비스 배포, 인증, 데이터 보호 기준 준수
결과	전사 AI 서비스에 필요한 프로덕션 운영 기준과 배포 흐름을 지원했습니다.
역량 포인트	수만 명 규모의 내부 사용자를 위한 애플리케이션 전달과 신뢰성을 리딩한 경험입니다.

Kubernetes · 사내 클러스터 · 애플리케이션 전달 · ArgoCD

프로젝트 상세

문제 상황, 역할, 설계/전달 포인트, 결과, 역량 포인트



05. GitOps CI/CD 파이프라인 with ArgoCD

컨테이너화된 AI/플랫폼 서비스를 위한 ArgoCD, Python 자동화, DevSecOps 기반 GitOps 배포 파이프라인

문제	컨테이너 기반 AI/플랫폼 서비스에 반복 가능하고 감사 가능한 보안 배포 흐름이 필요했습니다.
역할	AI 서비스 배포 자동화를 설계하고 보안 검증 단계를 배포 파이프라인에 연결했습니다.
설계/전달	ArgoCD GitOps, GitHub Actions, Docker 이미지 처리, Kubernetes 배포, Python 연동 자동화
결과	배포 일관성을 높이고 수동 릴리스 운영 의존도를 낮췄습니다.
역량 포인트	컨테이너 기반 서비스의 배포 일관성, 보안 검증, 운영 자동화를 연결한 경험입니다.

ArgoCD · GitHub Actions · Docker · Kubernetes



06. Kubernetes 클러스터 자동화

반복 가능한 개발/테스트 환경을 위한 Kubernetes 클러스터 원클릭 프로비저닝

문제	클라우드 개발자가 Kubernetes 환경을 매번 수동으로 준비해야 하는 부담이 있었습니다.
역할	Kubernetes 클러스터와 공통 플랫폼 모듈의 프로비저닝 자동화를 설계하고 구현했습니다.
설계/전달	Bash 기반 프로비저닝 자동화, 재사용 가능한 클러스터 모듈, 개발 환경 표준화
결과	수동 운영을 줄이고 클라우드 개발 환경의 일관성을 높였습니다.
역량 포인트	반복 가능한 개발/테스트 환경을 만들기 위한 플랫폼 자동화와 인프라 표준화 경험입니다.

Kubernetes · Bash

프로젝트 상세

문제 상황, 역할, 설계/전달 포인트, 결과, 역량 포인트

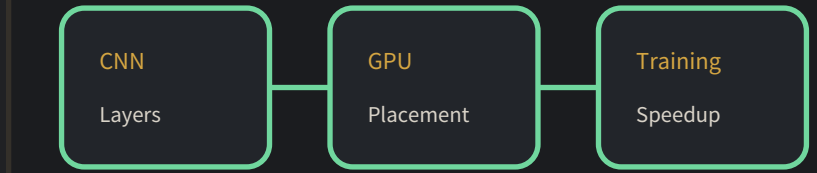


07. 고성능 패킷 미러링 애플리케이션

제한된 리소스에서 초당 최대 130,000개 패킷을 실시간 전달한 패킷 미러링 애플리케이션

문제	네트워크/애플리케이션 팀에서 제한된 시스템 리소스 안에서 실시간 패킷 전달이 필요했습니다.
역할	패킷 미러링 애플리케이션을 구현하고 리소스 제약 환경에서 동작하도록 조정했습니다.
설계/전달	고성능 I/O, Linux 런타임 동작, 리소스 제한, 실시간 데이터 전달
결과	초당 최대 130,000개 패킷을 전달할 수 있는 시스템 컴포넌트를 구현했습니다.
역량 포인트	Linux 런타임, 고성능 데이터 이동, 제한된 리소스에서의 성능 최적화를 다룬 경험입니다.

Linux · Networking · System Software · Performance



08. 분산 CNN 트레이닝 시스템

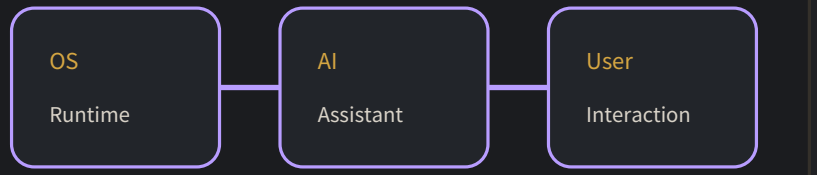
자동 리소스 인식 레이어 배치를 통한 CNN 분산 딥러닝 가속화 연구

문제	분산 CNN 학습에서 네트워크 병목과 비효율적인 레이어 배치 문제가 있었습니다.
역할	분산 TensorFlow/CNN 학습을 위한 리소스 인식 배치 연구에 기여했습니다.
설계/전달	분산 시스템, 모델 병렬화, 리소스 인식 스케줄링, TensorFlow, GPU 워크로드
결과	USENIX NSDI 2019 포스터와 arXiv 논문으로 연구 결과를 공개했고, 최대 2.3배 학습 속도 향상을 보고했습니다.
역량 포인트	분산 학습 워크로드의 네트워크 병목, 리소스 배치, 성능 개선을 연구한 경험입니다.

TensorFlow · Distributed Systems · AI Workloads · Python

프로젝트 상세

문제 상황, 역할, 설계/전달 포인트, 결과, 역량 포인트



09. TmaxOS 기반 Siri형 AI 어시스턴트

시스템 수준 통합과 자연스러운 사용자 경험을 제공하는 AI 어시스턴트

문제	OS 환경에서 사용자 상호작용과 시스템 기능을 연결하는 AI 어시스턴트가 필요했습니다.
역할	AI 추론 및 전처리 흐름을 구축하고 TmaxOS 수준 동작과 통합했습니다.
설계/전달	비동기 아키텍처, 시스템 통합, AI 모델 추론, 데이터 전처리
결과	비동기 설계를 통해 더 자연스러운 상호작용을 제공하는 AI 어시스턴트 경험을 구현했습니다.
역량 포인트	AI 기능을 OS 수준 동작, 비동기 처리, 사용자 상호작용과 연결해 구현한 경험입니다.

Python · AI/ML · TmaxOS · 비동기 프로그래밍



10. LLM 기반 클러스터 모니터링

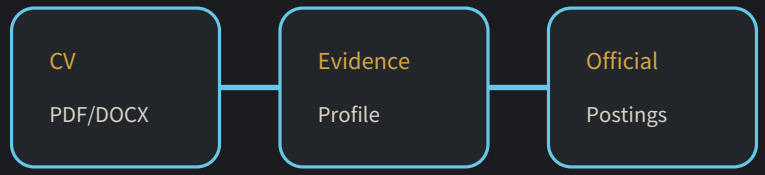
사내 클러스터 오류 감지, LLM 분석, 해결 방법의 이메일 보고를 연결한 개인 프로젝트입니다.

문제	클러스터 오류에 대한 단순 알림을 넘어, 문제 해석과 대응 방법을 함께 확인할 수 있어야 했습니다.
역할	사내 클러스터 운영을 위한 모니터링·보고 흐름을 개인 프로젝트로 구현했습니다.
설계/전달	오류 감지, LLM 기반 문제 분석, 문제 요약과 해결 방법의 이메일 전달을 연결했습니다.
결과	감지된 문제, LLM 분석 내용, 운영자가 검토할 해결 방법을 담은 이메일 보고를 구현했습니다.
역량 포인트	LLM을 클러스터 운영과 운영자 대상 오류 분석·보고에 적용한 경험입니다.

LLM · Cluster Monitoring · Email Alerts

프로젝트 상세

문제 상황, 역할, 설계/전달 포인트, 결과, 역량 포인트



11. 오퍼나우 (OfferNow)

개인 프로젝트: CV를 올리면 공식 채용 공고를 추천하고, 추천마다 근거가 된 CV 내용을 함께 보여주는 IT 채용 추천 서비스입니다.

문제	구직자는 자기 경력에 실제로 맞는 공고를 찾으려고 많은 공고를 읽어야 하고, 키워드 매칭은 확인할 수 있는 근거를 주지 않습니다.
역할	개인 프로젝트로 제품 정의, 백엔드, 모바일·웹 클라이언트, 데이터 수집, 배포를 직접 맡았습니다.
설계/전달	웹·iOS·Android용 Expo/React Native 클라이언트, FastAPI 백엔드, 행 수준 보안(RLS)과 익명 24시간 세션을 갖춘 PostgreSQL, 내구성 있는 작업 큐 기반 일일 수집기, 규칙 기반 매칭, 사용 한도와 비용 기록을 갖춘 공급자 중립 LLM 호출, GitHub Actions CI.
결과	베타 전 운영자 전용 입구 뒤로 heyoffernow.ai에 배포했고, 50여 개 기업의 공식 공고를 수집합니다.
역량 포인트	데이터 수집과 개인정보 보호부터 LLM 연동, 비용 한도, 배포까지 AI 제품 전체를 직접 만든 경험입니다.

Expo FastAPI PostgreSQL LLM Docker

요약 및 확인 링크

상세 프로젝트와 최신 CV는 온라인 포트폴리오에서 확인할 수 있습니다.

웹사이트

https://jinwonlee.github.io/

GitHub

https://github.com/JINwonLEE

LinkedIn

https://www.linkedin.com/in/jwl1993

Email

dlwlsdnjsehs1993@gmail.com

수상 및 활동

- SK하이닉스 AI 해커톤 2026 본선 진출 (2026.11): 온라인 1·2차 예선(AI 기초·활용 역량, AI Native 역량 검증)을 통과해 오프라인 본선에 진출 (개인 참가)

논문/발표

- Alleviating the Network Bottleneck for CNN Distributed Training through Automatic Resource-Aware Layer Placement — USENIX NSDI 2019 (2019)
- Accelerated Training for CNN Distributed Deep Learning through Automatic Resource-Aware Layer Placement — arXiv 2019 (2019)
- Improving Performance of Distributed TensorFlow using CNN Characteristics Exploiting Model Parallelism — ACM EuroSys 2018 (2018)

추가 경험: 기계 번역을 위한 LLM 평가 작업에 참여했습니다.

본 문서는 공개 가능한 경력/프로젝트 내용을 기반으로 정리한 제출용 포트폴리오입니다. 구체적인 내부 구현 세부사항이나 비공개 정보는 포함하지 않았습니다.