

이진원

AI Platform Software · MLOps/Serving · System Software

웹사이트

<https://jinwonlee.github.io/>

이 포트폴리오는 AI 애플리케이션을 실제 운영 가능한 서비스로 만들기 위해 수행한 플랫폼, 인프라, 서빙, 관측 가능성, 시스템 성능 관련 경험을 정리한 문서입니다. 각 프로젝트는 문제 상황, 담당 역할, 설계/운영 포인트, 결과 또는 배운 점을 중심으로 구성했습니다.



AI Platform Software

프로덕션 AI 서비스 운영,
Kubernetes 기반 플랫폼,
인증/관측성 통합



MLOps & Serving

LLM 평가, 모델 서빙 운영, GitOps
기반 반복 가능한 배포 흐름



System Software

Linux 런타임, 고성능 패킷 처리,
리소스 제약 기반 성능 작업




Cloud Infrastructure

Azure/AWS/OpenShift,
Helm/Helmfile, Terraform, Ansible
기반 자동화

프로젝트 상세

문제 상황, 역할, 설계/운영 포인트, 결과, 역량 포인트



01. 글로벌 B2C 생성형 AI 서비스

Azure 기반 프로덕션 생성형 AI 서비스의 모델 서빙 운영, 다중 리전 준비, Kubernetes 거버넌스

- 문제** 소비자 대상 생성형 AI 서비스를 글로벌 프로덕션 환경으로 확장해야 했습니다.
- 역할** Azure, Kubernetes 운영, 모델 서빙 배포 흐름, 인프라 거버넌스를 아우르는 플랫폼/SRE 설계를 담당했습니다.
- 설계/운영** AI 서빙 효율화, 다중 리전 배포, GitOps, 네트워크 설계, 보안 정책
- 결과** 보안성과 확장성을 고려한 프로덕션 AI 서비스 운영 모델을 구축했습니다.
- 역량 포인트** 프로덕션 AI 서비스의 서빙, 보안, 확장성, 다중 리전 운영 구조를 함께 설계한 경험입니다.


Kubernetes

Azure

AI Serving

ArgoCD

Python



02. 전사 AI 챗봇 플랫폼 (약 3만 사용자)

30,000명 임직원이 사용하는 엔터프라이즈 AI 챗봇 플랫폼의 Kubernetes, MLOps형 운영, 데이터 보호

- 문제** 수만 명의 임직원이 안정적으로 사용할 수 있는 내부 AI 어시스턴트 플랫폼이 필요했습니다.
- 역할** 개발, 스테이징, 프로덕션 Kubernetes 클러스터의 인프라/플랫폼/AI 애플리케이션 운영을 담당했습니다.
- 설계/운영** Kubernetes 운영, Helm/Helmfile IaC, AI 서비스 배포, 인증, 데이터 보호 기준 준수
- 결과** 전사 AI 서비스에 필요한 프로덕션 운영 기준과 배포 흐름을 지원했습니다.
- 역량 포인트** 수만 명 규모의 내부 사용자를 대상으로 Kubernetes 기반 AI 플랫폼 운영 기준을 다룬 경험입니다.

Kubernetes

사내 클러스터


MLOps

ArgoCD

Helm

프로젝트 상세

문제 상황, 역할, 설계/운영 포인트, 결과, 역량 포인트



03. 사내 AI 서비스 인프라 운영

브라우저 통합 AI와 Document LLM 서비스의 MLOps/SRE 운영, 인증, AI 관측 가능성

- 문제** 여러 내부 AI 서비스를 엔터프라이즈 인증과 AI 동작 관측이 가능한 형태로 운영해야 했습니다.
- 역할** Kubernetes 기반 AI 애플리케이션의 MLOps/SRE 운영과 플랫폼 통합을 담당했습니다.
- 설계/운영** Keycloak/OAuth 인증, Langfuse AI 관측 가능성, Kubernetes 런타임 운영, Python 자동화
- 결과** 보안, 서빙 상태, 런타임 가시성이 중요한 AI 서비스의 운영 통제력을 높였습니다.
- 역량 포인트** LLM 애플리케이션 운영을 인증, 관측 가능성, 런타임 안정성과 연결한 경험입니다.


Kubernetes

MLOps

Langfuse

Keycloak

OAuth



04. Kubernetes 클러스터 자동화

반복 가능한 개발/테스트 환경을 위한 Kubernetes 클러스터 원클릭 프로비저닝

- 문제** 클라우드 개발자가 Kubernetes 환경을 매번 수동으로 준비해야 하는 부담이 있었습니다.
- 역할** Kubernetes 클러스터와 공통 플랫폼 모듈의 프로비저닝 자동화를 설계하고 구현했습니다.
- 설계/운영** IaC 기반 프로비저닝, Python 자동화, 재사용 가능한 클러스터 모듈, 개발 환경 표준화
- 결과** 수동 운영을 줄이고 클라우드 개발 환경의 일관성을 높였습니다.
- 역량 포인트** 반복 가능한 개발/테스트 환경을 만들기 위한 플랫폼 자동화와 인프라 표준화 경험입니다.

Kubernetes

Terraform

Ansible

Python

프로젝트 상세

문제 상황, 역할, 설계/운영 포인트, 결과, 역량 포인트



05. LLM 성능 평가 파이프라인

기계 번역 태스크의 LLM 품질과 성능을 반복 평가하기 위한 MLOps형 파이프라인

- 문제** LLM 모델 품질을 임시 수동 확인이 아니라 반복 가능한 방식으로 평가해야 했습니다.
- 역할** 기계 번역 모델 비교를 위한 평가 워크플로우와 메트릭 추적 경로를 구축했습니다.
- 설계/운영** Python 평가 자동화, PyTorch 워크로드, MLflow 메트릭 추적, Kubernetes 실행 환경
- 결과** 모델 후보 간 LLM 평가 결과를 더 쉽게 비교하고 재현할 수 있게 했습니다.
- 역량 포인트** 모델 품질 비교를 자동화하고 평가 결과를 추적 가능한 흐름으로 만든 MLOps 경험입니다.

Python

PyTorch

MLflow

MLOps

Kubernetes



06. GitOps CI/CD 파이프라인 with ArgoCD

컨테이너화된 AI/플랫폼 서비스를 위한 ArgoCD, Python 자동화, DevSecOps 기반 GitOps 배포 파이프라인

- 문제** 컨테이너 기반 AI/플랫폼 서비스에 반복 가능하고 감사 가능한 보안 배포 흐름이 필요했습니다.
- 역할** AI 서비스 배포 자동화를 설계하고 보안 검증 단계를 배포 파이프라인에 연결했습니다.
- 설계/운영** ArgoCD GitOps, GitHub Actions, Docker 이미지 처리, Kubernetes 배포, Python 연동 자동화
- 결과** 배포 일관성을 높이고 수동 릴리스 운영 의존도를 낮췄습니다.
- 역량 포인트** 컨테이너 기반 서비스의 배포 일관성, 보안 검증, 운영 자동화를 연결한 경험입니다.

ArgoCD

GitHub Actions

Docker

Kubernetes

Python

프로젝트 상세

문제 상황, 역할, 설계/운영 포인트, 결과, 역량 포인트



07. 중앙 집중식 모니터링 & 관측성 스택

시스템 메트릭, 컨테이너 런타임 메트릭, 대시보드, 알람을 위한 중앙 관측성 스택

- 문제** 프로덕션 서비스의 시스템 동작과 컨테이너 런타임 상태를 공통으로 볼 수 있는 체계가 필요했습니다.
- 역할** 플랫폼 및 서비스 운영에 쓰이는 모니터링 경로와 대시보드를 구축했습니다.
- 설계/운영** Prometheus 메트릭, Grafana 대시보드, OpenTelemetry 신호, Loki 로그, 알람 규칙
- 결과** 인시던트 탐지와 런타임 분석을 위한 운영 가시성을 높였습니다.
- 역량 포인트** 시스템 메트릭, 로그, 트레이스를 모아 장애 탐지와 런타임 분석에 활용한 경험입니다.

Grafana

Prometheus

OpenTelemetry

Loki



08. 고성능 패킷 미러링 애플리케이션

제한된 리소스에서 초당 최대 130,000개 패킷을 실시간 전달한 패킷 미러링 애플리케이션

- 문제** 네트워크/애플리케이션 팀에서 제한된 시스템 리소스 안에서 실시간 패킷 전달이 필요했습니다.
- 역할** 패킷 미러링 애플리케이션을 구현하고 리소스 제약 환경에서 동작하도록 조정했습니다.
- 설계/운영** 고성능 I/O, Linux 런타임 동작, 리소스 제한, 실시간 데이터 전달
- 결과** 초당 최대 130,000개 패킷을 전달할 수 있는 시스템 컴포넌트를 구현했습니다.
- 역량 포인트** Linux 런타임, 고성능 데이터 이동, 제한된 리소스에서의 성능 최적화를 다룬 경험입니다.

Linux

Networking

System Software

Performance

프로젝트 상세

문제 상황, 역할, 설계/운영 포인트, 결과, 역량 포인트



09. 분산 CNN 트레이닝 시스템

자동 리소스 인식 레이어 배치를 통한 CNN 분산 딥러닝 가속화 연구


- 문제** 분산 CNN 학습에서 네트워크 병목과 비효율적인 레이어 배치 문제가 있었습니다.
- 역할** 분산 TensorFlow/CNN 학습을 위한 리소스 인식 배치 연구에 기여했습니다.
- 설계/운영** 분산 시스템, 모델 병렬화, 리소스 인식 스케줄링, TensorFlow, GPU 워크로드
- 결과** USENIX NSDI 2019 포스터와 arXiv 논문으로 연구 결과를 공개했고, 최대 2.3배 학습 속도 향상을 보고했습니다.
- 역량 포인트** 분산 학습 워크로드의 네트워크 병목, 리소스 배치, 성능 개선을 연구한 경험입니다.

TensorFlow

Distributed Systems

AI Workloads

Python



10. TmaxOS 기반 Siri형 AI 어시스턴트

시스템 수준 통합과 자연스러운 사용자 경험을 제공하는 AI 어시스턴트

- 문제** OS 환경에서 사용자 상호작용과 시스템 기능을 연결하는 AI 어시스턴트가 필요했습니다.
- 역할** AI 추론 및 전처리 흐름을 구축하고 TmaxOS 수준 동작과 통합했습니다.
- 설계/운영** 비동기 아키텍처, 시스템 통합, AI 모델 추론, 데이터 전처리
- 결과** 비동기 설계를 통해 더 자연스러운 상호작용을 제공하는 AI 어시스턴트 경험을 구현했습니다.
- 역량 포인트** AI 기능을 OS 수준 동작, 비동기 처리, 사용자 상호작용과 연결해 구현한 경험입니다.

Python

AI/ML

TmaxOS

비동기 프로그래밍

요약 및 확인 링크

상세 프로젝트와 최신 CV는 온라인 포트폴리오에서 확인할 수 있습니다.

웹사이트

<https://jinwonlee.github.io/>

GitHub

<https://github.com/JINwonLEE>

LinkedIn

<https://www.linkedin.com/in/jwl1993>

Email

dlwlsdnjsehs1993@gmail.com

논문/발표

- Alleviating the Network Bottleneck for CNN Distributed Training through Automatic Resource-Aware Layer Placement — USENIX NSDI 2019 (2019)
- Accelerated Training for CNN Distributed Deep Learning through Automatic Resource-Aware Layer Placement — arXiv 2019 (2019)
- Improving Performance of Distributed TensorFlow using CNN Characteristics Exploiting Model Parallelism — ACM EuroSys 2018 (2018)

본 문서는 공개 가능한 경력/프로젝트 내용을 기반으로 정리한 제출용 포트폴리오입니다. 구체적인 내부 구현 세부사항이나 비공개 정보는 포함하지 않았습니다.