

이진원

Agent 플랫폼 · Applied AI · 신뢰성

웹사이트

<https://jinwonlee.github.io/>

이 포트폴리오는 Agent App을 엔터프라이즈 요구사항에서 안정적인 프로덕션까지 전달하는 플랫폼과 신뢰성 엔지니어링 경험을 정리한 문서입니다. 각 프로젝트는 문제 상황, 담당 역할, 설계와 전달 포인트, 결과를 중심으로 구성했습니다.



Agent 플랫폼

Agent 런타임 연동, 셀프서비스 App 배포, 기존 LLM Gateway API 연결



거버넌스형 배포

인증·인가, 보안 통제, 자동 도메인 및 엔터프라이즈 거버넌스



신뢰성

관측 가능성, 장애 대응, 출시 준비 및 프로덕션 안정화




클라우드 런타임

AWS EKS, Azure, OpenShift, Kubernetes, Helm 및 ArgoCD

프로젝트 상세

문제 상황, 역할, 설계/전달 포인트, 결과, 역량 포인트



01. 사내 AX Agent Platform

자동 도메인, 접근 제어, 거버넌스, LLM Gateway 연동을 제공하는 AWS EKS 기반 AX App 배포·운영 플랫폼

- 문제** 개발팀이 AX App을 빠르게 배포하면서도 사내 접근 제어, 보안, AI 거버넌스를 일관되게 적용할 수 있어야 했습니다.
- 역할** 아키텍처와 구현부터 배포·운영까지 플랫폼 전달 전 과정을 담당하고 인증·인가·보안 및 사내 거버넌스를 책임졌습니다.
- 설계/전달** AWS EKS, AX Agent 런타임 조정, 도메인 자동 발급, 접근 제어, 정책 적용, 기존 LLM Gateway 클라이언트 연동
- 결과** 자동 도메인과 인가 사용자 전용 접근을 갖춘 AX App 셀프서비스 배포 경로를 구축했습니다.
- 역량 포인트** 런타임 호환성, 셀프서비스 배포, 접근 제어, 사내 LLM 연동을 하나의 거버넌스 플랫폼으로 구현한 경험입니다.


AWS

EKS

Kubernetes

인증/인가

거버넌스



02. 중앙 집중식 모니터링 & 관측성 스택

시스템 메트릭, 컨테이너 런타임 메트릭, 대시보드, 알람을 위한 중앙 관측성 스택

- 문제** 프로덕션 서비스의 시스템 동작과 컨테이너 런타임 상태를 공통으로 볼 수 있는 체계가 필요했습니다.
- 역할** 플랫폼 및 서비스 운영에 쓰이는 모니터링 경로와 대시보드를 구축했습니다.
- 설계/전달** Prometheus 메트릭, Grafana 대시보드, OpenTelemetry 신호, Loki 로그, 알람 규칙
- 결과** 인시던트 탐지와 런타임 분석을 위한 운영 가시성을 높였습니다.
- 역량 포인트** 시스템 메트릭, 로그, 트레이스를 모아 장애 탐지와 런타임 분석에 활용한 경험입니다.

Grafana


Prometheus

OpenTelemetry

Loki

프로젝트 상세

문제 상황, 역할, 설계/전달 포인트, 결과, 역량 포인트



03. 평가·접근 제어를 포함한 Enterprise AI Assistant

권한 인지 검색, 근거 인용, 감사 이벤트 및 반복 평가를 포함한 공개 레퍼런스 구현입니다.

- 문제** 채팅 프로토타입을 넘어 권한을 강제하고 동작을 평가하는 엔터프라이즈 AI 어시스턴트의 구현 방식을 보여주는 것이 목표였습니다.
- 역할** 레퍼런스 애플리케이션, 접근 정책, 검색 경로, Provider 인터페이스, 감사 모델, 평가 스위트, 테스트 및 브라우저 경험을 설계·구현했습니다.
- 설계/전달** Python, FastAPI, SQLite FTS5/BM25, 생성 전 역할 필터, 근거 인용, 감사 이벤트, 평가 케이스 및 선택적 OpenAI Responses API 연동.
- 결과** 인터랙티브 브라우저 데모와 자동화된 접근 안전성·검색 테스트를 포함한 백엔드 레퍼런스를 공개했습니다.
- 역량 포인트** 모델 품질 비교를 자동화하고 평가 결과를 추적 가능하고 반복 가능한 흐름으로 만든 경험입니다.


Python

FastAPI

SQLite FTS5

RBAC

Evaluations



04. 글로벌 B2C 생성형 AI 서비스

Microsoft Azure 기반 B2C 생성형 AI 서비스의 UK 확장, 초기 프로덕션 운영 및 장애 대응

- 문제** 소비자 대상 생성형 AI 서비스를 UK로 확장하고 초기 프로덕션 운영을 안정화해야 했습니다.
- 역할** UK 출시 준비, 초기 프로덕션 운영, 장애 대응 및 초기 안정화를 위한 플랫폼/SRE 업무를 수행했습니다.
- 설계/전달** Azure 및 Kubernetes 운영, 출시 준비, 프로덕션 안정화, 장애 대응
- 결과** UK 출시와 초기 안정화를 지원하고 2026년 6월 해당 업무를 마무리했습니다.
- 역량 포인트** 소비자 대상 생성형 AI 서비스의 UK 출시 준비, 초기 안정화, 장애 대응을 수행한 경험입니다.

Azure

Kubernetes


생성형 AI

SRE

장애 대응

프로젝트 상세

문제 상황, 역할, 설계/전달 포인트, 결과, 역량 포인트



05. 전사 AI 챗봇 플랫폼 (약 3만 사용자)

30,000명 임직원이 사용하는 엔터프라이즈 AI 챗봇 플랫폼의 Kubernetes 기반 애플리케이션 전달, 신뢰성, 데이터 보호

- 문제** 수만 명의 임직원이 안정적으로 사용할 수 있는 내부 AI 어시스턴트 플랫폼이 필요했습니다.
- 역할** 개발·스테이징·프로덕션 전반의 플랫폼 및 애플리케이션 신뢰성을 리딩하고 릴리스와 보안·운영 요구사항을 연결했습니다.
- 설계/전달** Kubernetes 운영, Helm/Helmfile IaC, AI 서비스 배포, 인증, 데이터 보호 기준 준수
- 결과** 전사 AI 서비스에 필요한 프로덕션 운영 기준과 배포 흐름을 지원했습니다.
- 역량 포인트** 수만 명 규모의 내부 사용자를 위한 애플리케이션 전달과 신뢰성을 리딩한 경험입니다.

Kubernetes

사내 클러스터

애플리케이션 전달

ArgoCD



06. GitOps CI/CD 파이프라인 with ArgoCD

컨테이너화된 AI/플랫폼 서비스를 위한 ArgoCD, Python 자동화, DevSecOps 기반 GitOps 배포 파이프라인

- 문제** 컨테이너 기반 AI/플랫폼 서비스에 반복 가능하고 감사 가능한 보안 배포 흐름이 필요했습니다.
- 역할** AI 서비스 배포 자동화를 설계하고 보안 검증 단계를 배포 파이프라인에 연결했습니다.
- 설계/전달** ArgoCD GitOps, GitHub Actions, Docker 이미지 처리, Kubernetes 배포, Python 연동 자동화
- 결과** 배포 일관성을 높이고 수동 릴리스 운영 의존도를 낮췄습니다.
- 역량 포인트** 컨테이너 기반 서비스의 배포 일관성, 보안 검증, 운영 자동화를 연결한 경험입니다.

ArgoCD

GitHub Actions

Docker

Kubernetes

Python

프로젝트 상세

문제 상황, 역할, 설계/전달 포인트, 결과, 역량 포인트



07. LLM 성능 평가 파이프라인

기계 번역 태스크의 LLM 품질과 성능을 반복 비교하기 위한 자동 평가 파이프라인

- 문제** LLM 모델 품질을 임시 수동 확인이 아니라 반복 가능한 방식으로 평가해야 했습니다.
- 역할** 기계 번역 모델 비교를 위한 평가 워크플로우와 메트릭 추적 경로를 구축했습니다.
- 설계/전달** Python 평가 자동화, PyTorch 워크로드, MLflow 메트릭 추적, Kubernetes 실행 환경
- 결과** 모델 후보 간 LLM 평가 결과를 더 쉽게 비교하고 재현할 수 있게 했습니다.
- 역량 포인트** 모델 품질 비교를 자동화하고 평가 결과를 추적 가능하고 반복 가능한 흐름으로 만든 경험입니다.

Python

PyTorch

MLflow

평가 자동화

Kubernetes



08. Kubernetes 클러스터 자동화

반복 가능한 개발/테스트 환경을 위한 Kubernetes 클러스터 원클릭 프로비저닝

- 문제** 클라우드 개발자가 Kubernetes 환경을 매번 수동으로 준비해야 하는 부담이 있었습니다.
- 역할** Kubernetes 클러스터와 공통 플랫폼 모듈의 프로비저닝 자동화를 설계하고 구현했습니다.
- 설계/전달** Bash 기반 프로비저닝 자동화, 재사용 가능한 클러스터 모듈, 개발 환경 표준화
- 결과** 수동 운영을 줄이고 클라우드 개발 환경의 일관성을 높였습니다.
- 역량 포인트** 반복 가능한 개발/테스트 환경을 만들기 위한 플랫폼 자동화와 인프라 표준화 경험입니다.

Kubernetes

Bash

프로젝트 상세

문제 상황, 역할, 설계/전달 포인트, 결과, 역량 포인트



09. 고성능 패킷 미러링 애플리케이션

제한된 리소스에서 초당 최대 130,000개 패킷을 실시간 전달한 패킷 미러링 애플리케이션

- 문제** 네트워크/애플리케이션 팀에서 제한된 시스템 리소스 안에서 실시간 패킷 전달이 필요했습니다.
- 역할** 패킷 미러링 애플리케이션을 구현하고 리소스 제약 환경에서 동작하도록 조정했습니다.
- 설계/전달** 고성능 I/O, Linux 런타임 동작, 리소스 제한, 실시간 데이터 전달
- 결과** 초당 최대 130,000개 패킷을 전달할 수 있는 시스템 컴포넌트를 구현했습니다.
- 역량 포인트** Linux 런타임, 고성능 데이터 이동, 제한된 리소스에서의 성능 최적화를 다룬 경험입니다.

Linux

Networking

System Software

Performance



10. 분산 CNN 트레이닝 시스템

자동 리소스 인식 레이어 배치를 통한 CNN 분산 딥러닝 가속화 연구

- 문제** 분산 CNN 학습에서 네트워크 병목과 비효율적인 레이어 배치 문제가 있었습니다.
- 역할** 분산 TensorFlow/CNN 학습을 위한 리소스 인식 배치 연구에 기여했습니다.
- 설계/전달** 분산 시스템, 모델 병렬화, 리소스 인식 스케줄링, TensorFlow, GPU 워크로드
- 결과** USENIX NSDI 2019 포스터와 arXiv 논문으로 연구 결과를 공개했고, 최대 2.3배 학습 속도 향상을 보고했습니다.
- 역량 포인트** 분산 학습 워크로드의 네트워크 병목, 리소스 배치, 성능 개선을 연구한 경험입니다.

TensorFlow

Distributed Systems

AI Workloads

Python

요약 및 확인 링크

상세 프로젝트와 최신 CV는 온라인 포트폴리오에서 확인할 수 있습니다.

웹사이트

<https://jinwonlee.github.io/>

GitHub

<https://github.com/JINwonLEE>

LinkedIn

<https://www.linkedin.com/in/jwl1993>

Email

dlwlsdnjsehs1993@gmail.com

논문/발표

- Alleviating the Network Bottleneck for CNN Distributed Training through Automatic Resource-Aware Layer Placement — USENIX NSDI 2019 (2019)
- Accelerated Training for CNN Distributed Deep Learning through Automatic Resource-Aware Layer Placement — arXiv 2019 (2019)
- Improving Performance of Distributed TensorFlow using CNN Characteristics Exploiting Model Parallelism — ACM EuroSys 2018 (2018)

본 문서는 공개 가능한 경력/프로젝트 내용을 기반으로 정리한 제출용 포트폴리오입니다. 구체적인 내부 구현 세부사항이나 비공개 정보는 포함하지 않았습니다.